

Laboratorio_13_Distribuciones_Probabilidad_Ley_Grandes_Números

June 15, 2026

1 Laboratorio 13

1.1 Distribuciones de probabilidad y ley débil de los grandes números

Este Jupyter Notebook, tiene contenido el código para estudiar las tres distribuciones de probabilidades continuas, en las que podemos enumerar:

1. Distribución uniforme.
2. Distribución exponencial.
3. Distribución normal o Gaussiana.

En este laboratorio se hace particular énfasis en que se realizarán derivaciones analíticas y simulaciones con `numpy.random`. Además del archivo del Jupyter Notebook, se procederá a entregar la copia en PDF del archivo para observar el resultado de su ejecución.

1.1.1 Sección de Desarrollo Algebraico de las Distribuciones

En esta sección, procedemos a armar con algunas celdas de Markdown, algunos de los desarrollos algebraicos que son necesarios para la ejecución de este laboratorio.

Distribución Uniforme $X \sim U(a, b)$ Donde tenemos la función de densidad de probabilidad, la cual se encuentra dada por:

$$p(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

Tenemos el valor esperado $E[X]$

$$E[X] = \int a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b$$
$$E[X] = \frac{1}{b-a} \left(\frac{b^2 - a^2}{2} \right) = \frac{(b-a)(b+a)}{2(b-a)} = \frac{a+b}{2}$$

Para la varianza $Var(X)$

Procedemos a calcular el segundo momento $E[X^2]$:

El cual se encuentra dado por:

$$E[X^2] = \int_a^b x^2 \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b = \frac{b^3 - a^3}{3(b-a)}$$

Y ahora procedemos a factorizar la diferencia de cubos, la cual se encuentra dada por:

$$E[X^2] = \frac{b^2 + ab + a^2}{3}$$

Y aplicando la identidad $Var(X) = E[X^2] - E[X]^2$:

$$Var(X) = \frac{b^2 + ab + a^2}{3} - \left(\frac{a+b}{2} \right)^2 = \frac{b^2 + ab + a^2}{3} - \frac{a^2 + 2ab + b^2}{4}$$

Y al homogenizar fracciones, nos queda ahora que:

$$Var(X) = \frac{4b^2 + 4ab + 4a^2 - 3a^2 - 6ab - 3b^2}{12} = \frac{a^2 - 2ab + b^2}{12} = \frac{(b-a)^2}{12}$$

Sección de la Distribución Exponencial $X \sim Exp(\lambda)$ En esta sección, dada la función de densidad de probabilidad:

$$p(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Procedemos a calcular el valor esperado $E[X]$

$$E[X] = \int_0^\infty x \lambda e^{-\lambda x} dx$$

Y ala hora de aplicar integración por partes donde tenemos ahora que:

$$\begin{aligned} u = x &\implies du = dx \\ dv = \lambda e^{-\lambda x} dx &\implies v = -e^{-\lambda x} \end{aligned}$$

Y tenemos ahora que esto nos queda de la forma:

$$E[X] = [-xe^{-\lambda x}]_0^\infty - \int_0^\infty (-e^{-\lambda x}) dx$$

Y finalmente, tenemos el primer término que se evalúa en 0 por el límite cuando $x \rightarrow \infty$. Evaluamos la integral restante:

$$E[X] = \left[-\frac{1}{\lambda} e^{-\lambda x} \right]_0^\infty = 0 - \left(-\frac{1}{\lambda} \right) = \frac{1}{\lambda}$$

Y finalmente, procedemos a calcular la varianza $Var(X)$:

Y tenemos ahora que $E[X^2]$:

$$E[X^2] = [-x^2]e^{-\lambda x} \Big|_0^\infty + 2 \int_0^\infty x e^{-\lambda x} dx$$

Donde nos queda ahora que este término resulta de la forma, luego de algunos arreglos algebraicos:

$$E[X^2] = \frac{2}{\lambda} E[X] = \frac{2}{\lambda} \left(\frac{1}{\lambda} \right) = \frac{2}{\lambda^2}$$

La varianza queda de la forma: $Var(X) = E[X^2] - E[X]^2$:

$$Var(X) = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda} \right)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

```
[9]: # Procedemos a importar las librerías necesarias para realizar el estudio para
      ↪ las distribuciones
import numpy as np
import matplotlib.pyplot as plt # Necesaria para las gráficas
```

```
[10]: # Procedemos a definir los parámetros de las distribuciones

a, b = 0, 1
lambda_param = 2
mu, sigma = 0, 1
# Procedemos a generar los valores de N iteraciones

N_values = [10**1, 10**2, 10**3, 10**4, 10**5, 10**6]

# Y podemos colocar un diccionario para guardar los resultados numéricos de las
      ↪ tres distribuciones

resultados = {
    'Uniforme': {'emp_mean': [], 'emp_var': [], 'theo_mean': (a+b)/2, 'theo_var':
      ↪ (b-a)**2/12},
    'Exponencial': {'emp_mean': [], 'emp_var': [], 'theo_mean': 1/lambda_param,
      ↪ 'theo_var': 1/lambda_param**2},
    'Normal': {'emp_mean': [], 'emp_var': [], 'theo_mean': mu, 'theo_var': sigma**2},
}

# Colocamos una semilla de reproducibilidad, en donde colocamos ahora invocamos
      ↪ a la librería numpy para esto

np.random.seed(42)

# Procedemos a colocar una simulación numérica y cálculo de promedios /
      ↪ varianzas empíricas
```

```

for N in N_values:
    # Con este bucle for, procedemos a generar muestras aleatorias para
    ↪integrar nuestro método

    muestras_uniformes = np.random.uniform(a,b,N)
    muestras_exponencial = np.random.exponential(1/lambda_param, N)
    muestras_normal = np.random.normal(mu, sigma, N)

    # Procedemos a colocar la distribución uniforme

    resultados['Uniforme']['emp_mean'].append(np.mean(muestras_uniformes))
    resultados['Uniforme']['emp_var'].append(np.var(muestras_uniformes))

    # Para nuestra distribución exponencial, colocamos ahora que:

    resultados['Exponencial']['emp_mean'].append(np.mean(muestras_exponencial))
    resultados['Exponencial']['emp_var'].append(np.var(muestras_exponencial))

    # Colocamos la distribución normal

    resultados['Normal']['emp_mean'].append(np.mean(muestras_normal))
    resultados['Normal']['emp_var'].append(np.var(muestras_normal))

# Procedemos a generar los gráficos claros de cada distribución para este caso

for dist_name, data in resultados.items():
    fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14,5))
    fig.suptitle(f'Ley Débil de los Grandes Números - Distribución
    ↪{dist_name}', fontsize=14, fontweight='bold')

    # Colocamos la gráfica de promedio empírico vs los valores N

    ax1.plot(N_values, data['emp_mean'], marker='o', color='royalblue',
    ↪label='Promedio Empírico ( $\overline{X}_N$ )')
    ax1.axhline(y=data['theo_mean'], color='crimson', linestyle='--',
    ↪label=f'Valor Teórico ({data["theo_mean"]:.4f})')
    ax1.set_xscale('log')
    ax1.set_xlabel('Número de muestras ($N$)', fontsize=11)
    ax1.set_ylabel('Promedio', fontsize=11)
    ax1.set_title('Convergencia del Promedio')
    ax1.grid(True, which="both", linestyle = ':', alpha=0.6)
    ax1.legend()

    # Realizamos la gráfica de Varianza Empírica contra los valores de N

```


```

ax2.plot(N_values, data['emp_var'], marker='s', color='darkorange',
label='Varianza Empírica($s_N^2$)')
ax2.axhline(y=data['theo_var'], color='crimson', linestyle='--',
label=f'Varianza Teórica ({data["theo_var"]:.4f})')
ax2.set_xscale('log') # Escala logarítmica para el eje horizontal
ax2.set_xlabel('Número de muestras ($N$)', fontsize=11)
ax2.set_ylabel('Varianza', fontsize=11)
ax2.set_title('Convergencia de la Varianza')
ax2.grid(True, which='both', linestyle=':', alpha=0.6)
ax2.legend()


plt.tight_layout()
plt.show()

```


Ley Débil de los Grandes Números - Distribución Uniforme



Ley Débil de los Grandes Números - Distribución Exponencial



Ley Débil de los Grandes Números - Distribución Normal



```
[11]: # Y colocamos una impresión para verificar numéricamente el output

print(f"{'Distribución':<15} | {'N':<8} | {'Media Emp.':<10} vs {'Media Teo.':<10} | {'Var Emp.':<10} vs {'Var Teo.':<10}")
print("-" * 78)
for dist_name, data in resultados.items():
    for i, N in enumerate(N_values):
        print(f"{'dist_name':<15} | {'N':<8} | {data['emp_mean'][i]:.5f} vs {data['theo_mean'][i]:.5f} | {data['emp_var'][i]:.5f} vs {data['theo_var'][i]:.5f}")
    print("-" * 200)
```

Distribución	N	Media Emp. vs Media Teo.	Var Emp. vs Var Teo
Uniforme	10	0.52014 vs 0.50000	0.08979 vs 0.08333
Uniforme	100	0.49078 vs 0.50000	0.09174 vs 0.08333
Uniforme	1000	0.50015 vs 0.50000	0.08749 vs 0.08333
Uniforme	10000	0.49479 vs 0.50000	0.08274 vs 0.08333
Uniforme	100000	0.49953 vs 0.50000	0.08339 vs 0.08333
Uniforme	1000000	0.50006 vs 0.50000	0.08322 vs 0.08333

Exponencial	10	0.39846 vs 0.50000	0.25944 vs 0.25000
Exponencial	100	0.46999 vs 0.50000	0.20298 vs 0.25000
Exponencial	1000	0.49858 vs 0.50000	0.24563 vs 0.25000
Exponencial	10000	0.51516 vs 0.50000	0.26201 vs 0.25000
Exponencial	100000	0.50331 vs 0.50000	0.25346 vs 0.25000
Exponencial	1000000	0.49945 vs 0.50000	0.25001 vs 0.25000

Normal	10	-0.35697 vs 0.00000	0.72116 vs 1.00000
--------	----	---------------------	--------------------

Normal	100	0.03687 vs 0.00000	1.19216 vs 1.00000
Normal	1000	0.01824 vs 0.00000	0.94521 vs 1.00000
Normal	10000	-0.00729 vs 0.00000	0.98072 vs 1.00000
Normal	100000	-0.00079 vs 0.00000	0.99955 vs 1.00000
Normal	1000000	0.00015 vs 0.00000	0.99988 vs 1.00000
